



# Redes Convolucionais Profundas para Classificação de Resíduos em Usinas de Triagem: Uma Abordagem com Transfer Learning e Validação Cruzada K-Fold

Squad 1:  
Franciscleide Lauriano

**CICLO 2025.2** **BOOTCAMP  
DEMO  
DAY**

Fortaleza - CE, 26 de julho de 2025.



# Introdução:

## Desafios na Triagem de Resíduos

A triagem manual de resíduos sólidos urbanos em usinas enfrenta:

Baixa Produtividade

Processos lentos e ineficientes.

Ambientes Insalubres

Exposição a condições de trabalho perigosas.

Alto Erro Humano

Classificação imprecisa dos materiais.

Machine Learning e Visão Computacional oferecem uma alternativa promissora para automação.







# Objetivos da Etapa

1

## Modelo Próprio

Desenvolver e avaliar um modelo próprio para classificação de resíduos.

2

## Balanceamento de Dados

Corrigir o desbalanceamento das classes.

3

## Comparar Modelos

Comparar com o modelo da literatura: Recycle-ResNet-MobileNet-Ensembled.

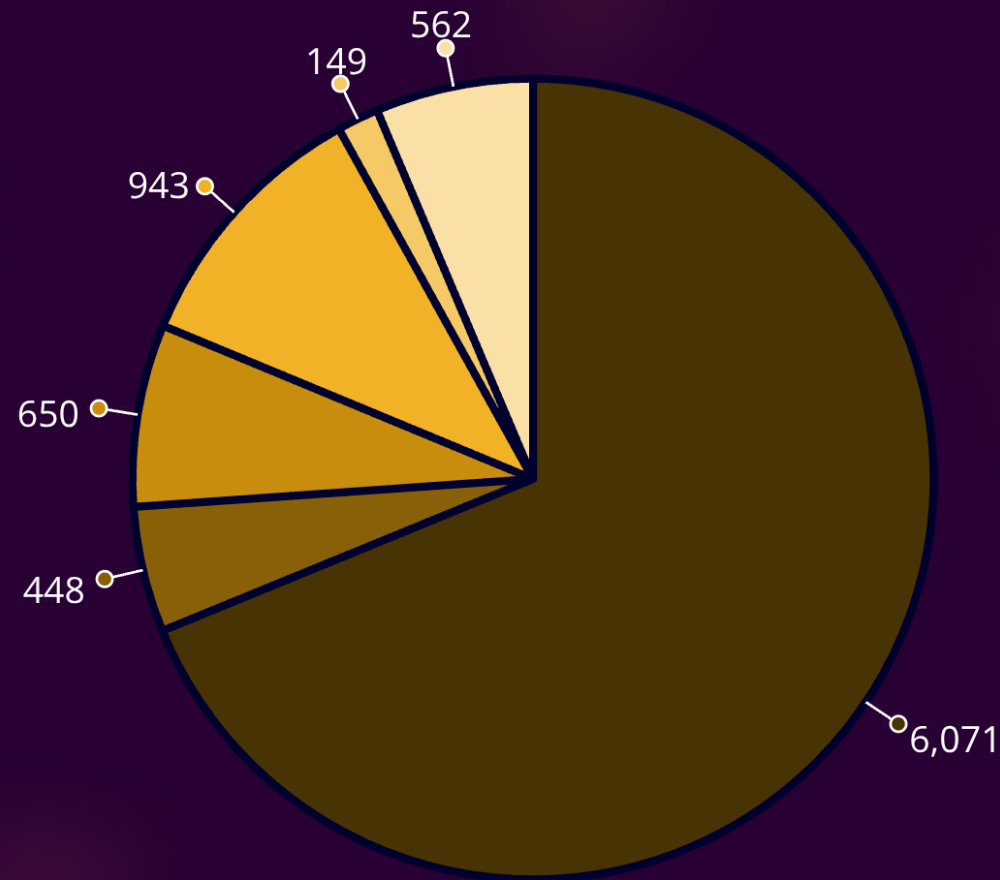
4

## Apresentar Resultados

Apresentar métricas, visualizações e conclusões.

# Desafio: Dataset Desbalanceado

Nosso dataset de 8.823 imagens de resíduos recicláveis apresenta um desbalanceamento severo:



■ Bottle ■ Glass ■ Cardboard ■ Detergent ■ Canisters ■ Cans



## Riscos no treinamento:

- Viés do modelo para a classe majoritária.
- Baixa generalização e desempenho insatisfatório nas classes minoritárias.
- Redução da métrica F1-Score Macro e Recall por classe.
- Resultados enganosos se avaliados apenas por acurácia.

A classe "Bottle" representa ~69% das amostras, enquanto "Cans" e "Glass" têm menos de 500 amostras. Sem tratamento, o modelo favorecerá a classe majoritária.

# Metodologia Própria: Arquitetura e Estratégia

## 1 Backbone

ResNet50 pré-treinada no ImageNet (Transfer Learning), com camadas superiores removidas.

## 2 Camadas Adicionais

- GlobalAveragePooling2D()
- Dropout(0.5)
- Dense(128, activation='relu')
- BatchNormalization()
- Dropout(0.5)
- Dense(6, activation='softmax')

## 3 Técnicas Aplicadas

- Técnicas aplicadas para lidar com o desbalanceamento:
  - Undersampling seletivo da classe majoritária
  - Data Augmentation (rotação, zoom, brilho, flips)
  - Pesos das classes para compensar desbalanceamento: `class_weight`
- Normalização das imagens (rescale): `1./255`
- EarlyStopping com `patience=5`
- Otimizador: Adam com `learning_rate=1e-5`



# Validação Cruzada e Avaliação



## K-Fold Cross-Validation (n\_splits=5)

Estratificada, com shuffle e seed (random\_state=42), para avaliação confiável e sem viés de partição.



## Métricas Avaliadas por Fold

Accuracy, Precision, Recall, F1-Score (macro), AUC-ROC (macro e por classe), Cohen's Kappa, Matriz de Confusão.





## Critérios de Desempenho

Baseados na literatura (He et al., Kohavi, Sammut & Webb, Fawcett).





# Curvas de Treinamento Fold 1 – Método Próprio





# Curvas de Treinamento Fold 2 – Método Próprio

Treinamento - Fold 2







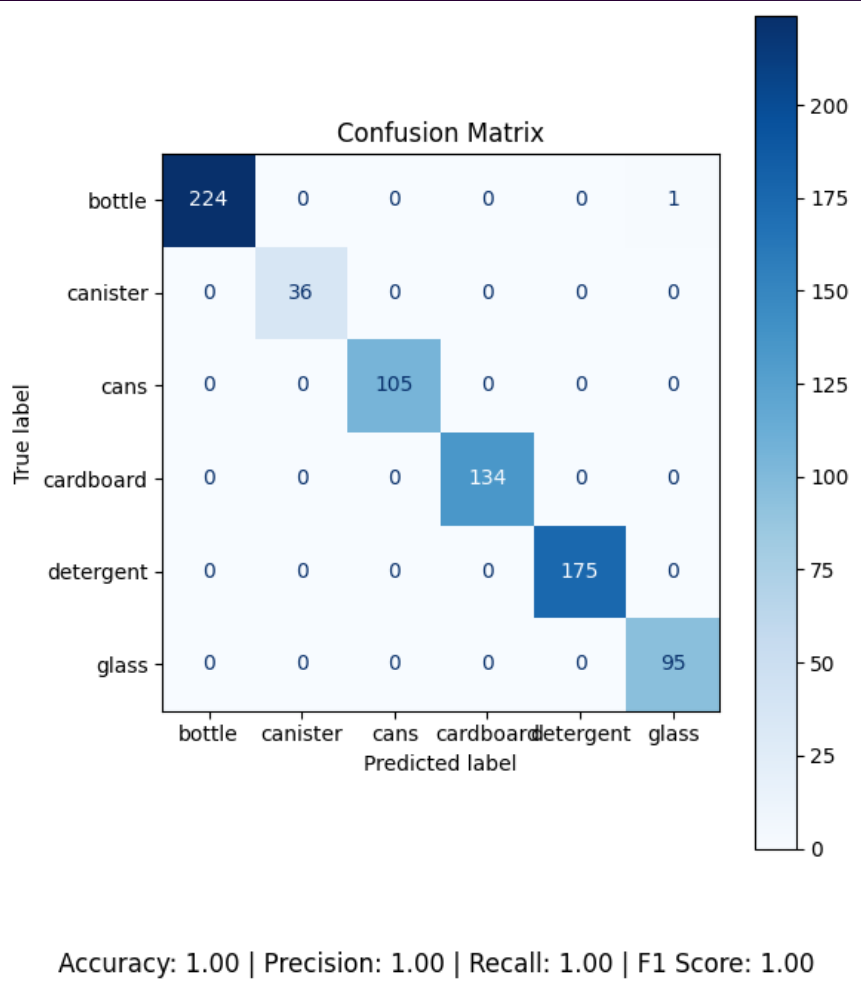

# Curvas de Treinamento Fold 3 – Método Próprio



# Curvas de Treinamento Fold 4 – Método Próprio




# Curvas de Treinamento Fold 5 – Método Próprio



# Matriz de Confusão

## Agregada – Método Próprio




MÉTRICAS FINAIS – CROSS- VALIDATION (5 folds)		
Métrica	Média	Desvio Padrão
Accuracy	0.9460	0.0688
Precision (macro)	0.9352	0.0800
Recall (macro)	0.9541	0.0606
F1-Score (macro)	0.9427	0.0729
Cohen's Kappa	0.9326	0.0858
AUC-ROC (macro)	0.9926	0.0119

AUC-ROC por Classe		
Classe	AUC Média	Desvio Padrão
bottle	0.9876	0.0181
canister	0.9936	0.0121
cans	0.9963	0.0071
cardboard	0.9962	0.0073
detergent	0.9855	0.0208
glass	0.9961	0.0064

Excelente desempenho em todas as classes. Confusão residual: bottle, cardboard e detergent.




# Comparação entre os Métodos



## Método da Literatura\*

\* **Notebook** Recycle-ResNet-MobileNet-Ensembled (Kaggle),  
Autor: Abdel-Hamid-M-Aljamal

## Método Próprio



# Comparação entre os Métodos

Critério	Modelo Próprio	Método da Literatura*
Arquitetura	ResNet50 + camadas adaptadas	Ensemble: ResNet + MobileNet
Validação	K-Fold (5 folds)	Split simples
Técnicas adicionais	Data Augmentation, Undersampling, class weight	Data Augmentation
Accuracy	0.9442 ± 0.0715	~ 0.87
AUC-ROC (macro)	0.9931 ± 0.0114	Não informado
Robustez frente a ruído	Alta (validação estratificada)	Baixa
Confusão entre classes	Baixa	Alta (bottle ↔ cardboard ↔ detergent)

\* **Notebook** Recycle-ResNet-MobileNet-Ensembled (Kaggle), Autor: Abdel-Hamid-M-Aljamal  
Link: <https://www.kaggle.com/code/abdelhameedmaljamal/recycle-resnet-mobilenet-ensembled>

# Conclusões e Próximos Passos

1

Modelo Proposto Superou a Literatura

Desempenho superior, mais robusto e menor confusão entre classes.

2

Contribuições

Estratégia leve, eficaz e replicável para automação de triagem.

3

Próximos Passos

Testar redes mais leves, otimizar para dispositivos embarcados e aumentar o dataset.

# Referências Bibliográficas

- Aljamal, Abdel-Hamid-M. Recycle ResNet MobileNet Ensembled. Kaggle, 2023. Disponível em: <https://www.kaggle.com/code/abdelhameedmaljamal/recycle-resnet-mobilenet-ensembled>. Acesso em: 07 jul. 2025.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37–46.
- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874.
- He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778.
- Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.
- Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 1137–1143.
- Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1), 159–174.
- Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10), 1345–1359.
- Sammut, C., & Webb, G. I. (2010). *Encyclopedia of Machine Learning*. Springer.
- Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation for deep learning. *Journal of Big Data*, 6(1), 60.
- Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427–437.